Sensor2Sensor

Cross-Embodiment Sensor conversion for Autonomous Driving

CVPR 2026 | Wang et al. | Waymo · Johns Hopkins University · Google DeepMind · University of Washington

충북대학교 지능로봇공학과 구자경

2026.10.19

AVLAB AUTONOMOUS VEHICLE CBNU

Need for Vehicle-Specific Sensor Data

대규모 다중 센서 주행 데이터와 외부 영상 활용 경험 보유

주행 규모: 10개 이상 도시에서 운전자 없는 완전 자율 주행으로 약 2억 마일 누적

로그 구성: 로보택시마다 카메라·LiDAR·레이더 데이터를 시간 동기화해 저장, 장면을 3D로 다시 복원할 수 있는 원천 데이터

외부 영상 활용: 블랙박스 업체 Nexar의 Dashcam 주행 데이터 5억 마일 이상에서 보행자·자전거 충돌 335건을 재구성해 안전 연구에 사용

차량 플랫폼과 운행 지역 확대

6세대 Driver: Ojai, IONIQ 5 등 새 차량마다 센서 구성을 다시 맞춰 탑재, 카메라 수는 5세대(Jaguar I-PACE)의 절반 미만

양산 차량: Toyota 차세대 개인 소유 차량에 Waymo 자율주행 기술 적용 검토(2025.04 예비 합의), 로보택시 외 차종으로 확대

운행 지역: 극한 겨울 날씨 지역 운행 준비, 기존 운행 도시의 데이터에 없던 환경

차량별 센서 형식에 맞는 검증 데이터 필요

센서 구성 차이: 차량마다 카메라 수·위치와 LiDAR 구성이 달라, 검증도 차량(embodiment)마다 따로 해야 함

검증 방식: 시뮬레이션을 주요 안전 검증 수단으로 사용, 사고 상황과 도로·건물·날씨·조명 환경을 다양하게 구성하는 데 드는 시간과 비용

수집 한계: 충돌 직전 같은 드문 위험 장면은 자체 차량 운행만으로 충분히 모으기 어려움

➡ Dashcam(블랙박스)·in-the-wild 단안 영상을 대상 차량 형식의 대규모 AV 로그로 바꾸는 연구 필요

Embodiment Gap of In-the-wild Video

드물지만 위험한 long-tail 장면의 직접 수집 필요

검증 방식: 차량(embodiment)마다 따로 하는 ADS(Automated Driving System) 검증

수집 비용: 차량단 규모의 장기 운행에 드는 투자와 인프라

생성 모델·시뮬레이터로 장면을 처음부터 만드는 합성 방식의 한계

움직임: 물리적으로 맞지 않는 움직임(plausibility gap)

센서 데이터: 실제처럼 보이지 않는 생성 결과(realism problem)

장면 구성: 사고 상황과 주변 환경을 사람이 직접 설계해야 하는 시뮬레이터

In-the-wild 영상과 대상 차량 사이의 embodiment gap

사실성: 실제 사건 기반, 드문 사고 장면과 다양한 도로·날씨·조명 환경(인터넷, 협력사 차량 dashcam)

센서 형식: 단안 영상 1개, 360도 시야와 LiDAR 부재

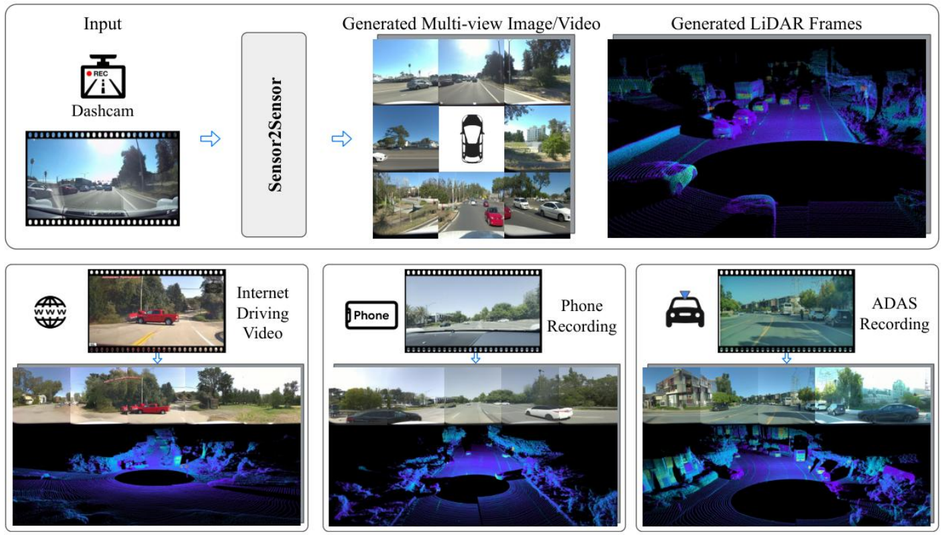


Figure 1. 다양한 출처의 in-the-wild 단안 영상을 대상 차량의 카메라·LiDAR 로그로 변환하는 과제

* Embodiment: 센서의 종류, 개수, 장착 위치를 합친 구성

* In-the-wild: 통제된 수집 절차 없이 일반 환경에서 찍힌 영상(dashcam, 인터넷, 휴대폰, 다른 ADAS(Advanced Driver Assistance System))

3D Gaussian Splatting and Diffusion Models

3D Gaussian Splatting(3DGS): 사진 여러 장으로 장면을 3D로 복원

표현: 위치, 크기, 회전, 불투명도, 색을 가진 수많은 3D 가우시안

렌더링: 화면에 투영한 뒤 카메라에 가까운 것부터 불투명도만큼 색을 겹쳐 그리는 방식

최적화: 렌더링 결과와 실제 사진의 차이를 줄이는 방향, 학습 후 새 시점의 실시간 렌더링

한계: 학습에 쓴 카메라 위치에서 멀어질수록 떨어지는 품질

4DGS(4D Gaussian Splatting): 시간 축을 더해 움직이는 물체까지 표현하는 3DGS 변형

표현: 정적 배경과 움직이는 차량·보행자를 나눠 물체마다 시간별 위치와 모양

확산 모델(diffusion model): 노이즈를 단계적으로 걷어 내며 데이터를 만드는 생성 모델

학습: 여러 단계의 노이즈를 섞은 데이터에서 원래 데이터를 되살리는 학습

생성: 순수한 노이즈에서 시작하는 단계적 노이즈 제거

논문에서 쓰는 Diffusion 모델의 형태

조건부 확산: 주어진 입력(dashcam 영상)에 맞춘 생성

잠재 확산(latent diffusion): VAE로 압축한 작은 공간(latent)에서 수행해 계산량 절감

* 3DGS(3D Gaussian Splatting): Kerbl et al., ACM TOG(SIGGRAPH) 2023
* VAE(Variational Autoencoder): 데이터를 작은 latent로 압축하고 다시 복원하는 모델

Absence of Paired Dashcam–AV Data

Dashcam(블랙박스) 영상과 AV 로그가 짝지어진 paired data 부재

필요: 같은 순간을 두 센서로 함께 기록한 데이터

현실: 자율주행 차량 센서가 아닌 dashcam, 어떤 데이터셋에도 없는 짝 데이터

AV 로그에 이미 담긴 장면의 3D 정보

구성: 360도를 덮는 카메라와 LiDAR

활용: 4DGS로 장면 복원 가능

복원한 장면의 dashcam 시점 렌더링으로 paired data 생성

입력과 정답: 렌더링한 dashcam 영상과 원래 AV 로그

정렬: 프레임마다 맞는 시간과 위치

의미: 복원 결과를 geometric oracle(GT 기하)로 사용, 지도학습 문제로 전환

부가 효과: 흐림·잡티가 섞인 입력으로 학습해 생기는 잡음 제거 효과, 실제 입력에 대한 강건성

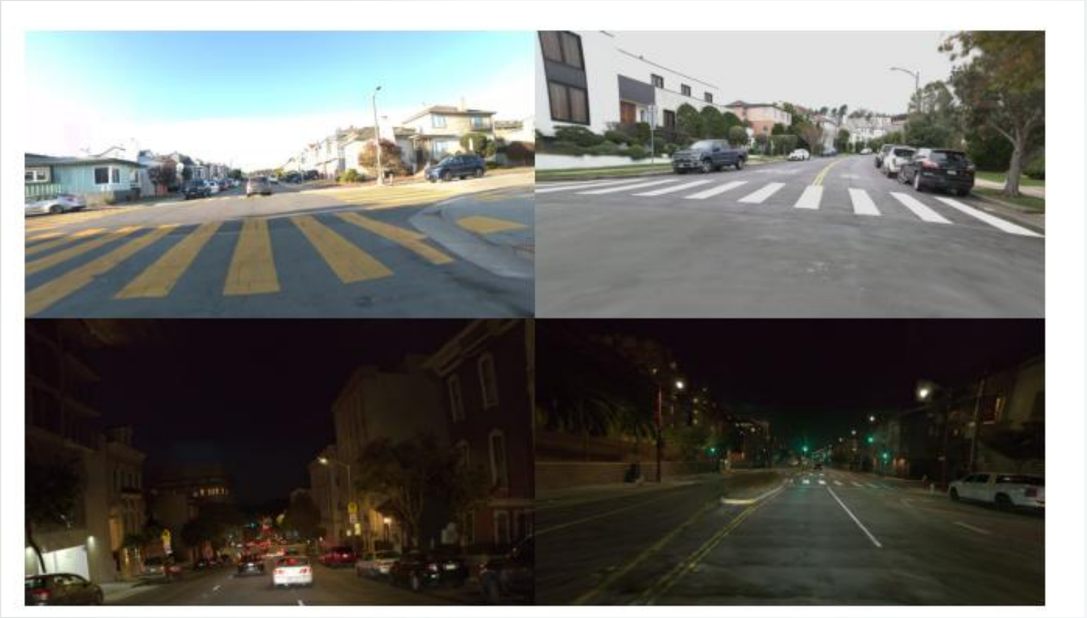


Figure 15. 4DGS에서 여러 카메라 설정으로 렌더링한 합성 dashcam 영상

* AV(Autonomous Vehicle) 로그: 자율주행 차량이 기록한 카메라·LiDAR 데이터
* Paired data: 입력과 정답이 짝지어진 데이터

Limits of Reconstruction and Translation Methods

이 과제에 그대로 쓰기 어려운 기존 접근

Unpaired translation(짝 없는 도메인 변환): 3D 기하 정보와 다중 센서 생성 능력 부재, 단일 영상에서 일관된 다중 센서 생성 곤란

복원 기반 방법(VGGT, π^3, 3DGS): 입력이 보지 못한 시점의 빈 영역, 원래 카메라 근처에서만 높은 품질

생성형 월드 모델(GAIA-1, Cosmos): 시나리오 생성·미래 예측·폐루프 시뮬레이션 목적, 데이터 변환과 다른 목표

같은 차량의 센서 간 변환(intra-embodiment)에서 확인된 조건부 확산을 차량 간 변환(cross-embodiment)으로 확장

LiDM(LiDAR Diffusion Model): 카메라 영상을 조건으로 한 LiDAR 생성

X-Drive: LiDAR와 다중 카메라 영상의 두 분기 동시 생성, 두 모달 사이의 일관성 확보



Figure 4. 이미지 생성 비교. 기준선은 장면 구조가 무너지거나 보이지 않던 영역을 자연스럽게 채우지 못함(저자 설명)

* VGGT(Visual Geometry Grounded Transformer, CVPR 2025), π^3(ICLR 2026): 이미지에서 카메라 위치와 3D 점을 한 번에 예측하는 복원 모델
* X-Drive(ICLR 2025)
* GAIA-1(Generative AI for Autonomy, Wayve), Cosmos(NVIDIA)

Paired Data from 4DGS Rendering

Waymo 로그의 10초 장면 약 10만 개를 4DGS로 복원

입력 로그: 360도를 덮는 카메라 8대와 상단 LiDAR

객체 표현: 차량은 rigid(모양 고정), 보행자는 deformable(모양 변화)

움직이는 물체: 여러 프레임의 관측을 물체 기준 좌표계에 누적

LiDAR 역할: 기하 초기화와 보정

렌더링: 어안 렌즈를 위한 ray tracing(광선 추적), 노출·감마 보정

실제 분포에서 뽑은 가상 Dashcam(블랙박스) 카메라 설정

Intrinsic parameters: Nexar, VIOFO 등 실제 dashcam 보정값

Extrinsic parameters: 차종별 장착 위치·각도 분포

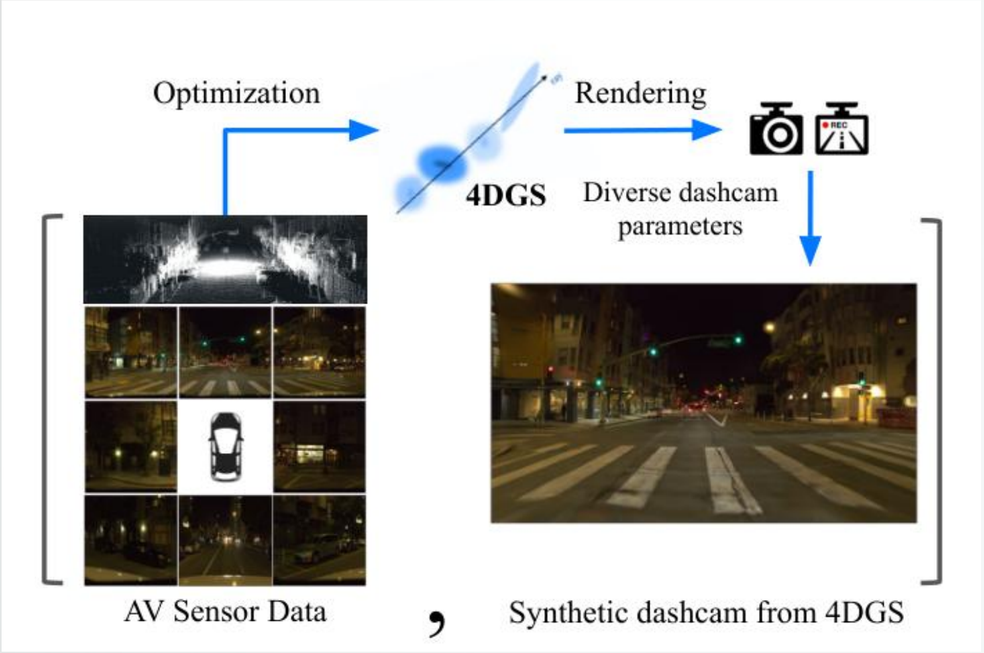


Figure 2. 카메라 8대로 4DGS를 복원하고 여러 dashcam 시점을 렌더링해 paired data를 만드는 과정

* Ray tracing: 픽셀마다 광선을 쏘아 색을 모으는 렌더링 방식

Joint Camera–LiDAR Diffusion Model

하나의 잠재 확산 모델로 카메라 8대 영상과 LiDAR 동시 생성

입출력: 보정되지 않은 단안 Dashcam(블랙박스) 영상 입력, 시간이 맞춰진 카메라 8대 영상과 LiDAR 출력

학습·추론 입력: 학습은 4DGS로 렌더링한 합성 dashcam 영상, 추론은 실제 dashcam 영상

생성 공간: 이미지와 LiDAR 각각의 VAE latent(이미지 8채널, LiDAR 16채널)

LiDAR 표현: range-view spin image(행은 위아래 각도, 열은 좌우 각도, 칸마다 거리·반사 강도·elongation·유효 여부)

두 종류의 attention으로 출력 간 일관성 유지

Cross-view attention: 시점 축 1D와 공간 축 2D를 합친 3D attention, 8개 카메라 영상 사이의 참조

Cross-sensor attention: U-Net 블록마다 이미지·LiDAR 토큰을 이어 붙인 self-attention, 이미지와 LiDAR 사이의 참조

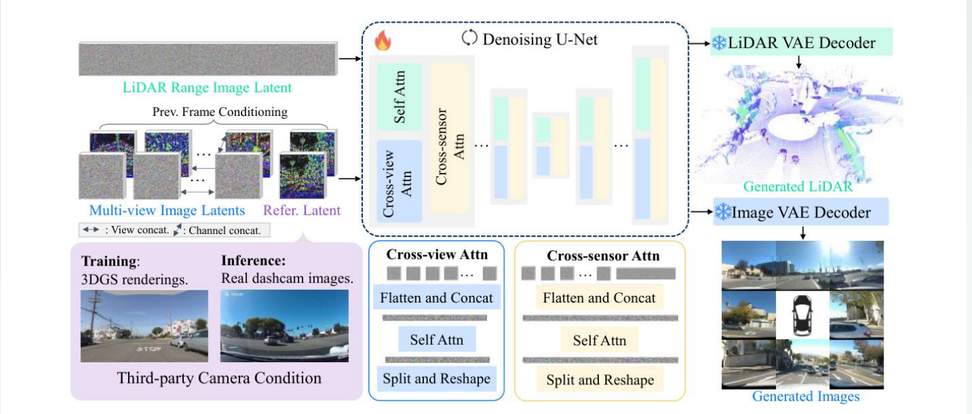


Figure 3. 이미지와 LiDAR를 각각 VAE로 압축한 latent 공간에서 함께 생성하는 구조

Dashcam 조건 입력

VC(view concatenation): 9번째 시점으로 시점 방향 연결, attention으로 8개 카메라와 직접 정보 교환, loss는 대상 8개 시점에만 계산

CC(channel concatenation): dashcam latent의 채널 방향 연결

Raymap: 첫 카메라 기준으로 정규화한 카메라 위치와 방향

마스킹: 학습 중 확률 0.2로 dashcam 영역 일부를 가림, 추론 때 워터마크·자차 보닛 마스킹에 사용

* 이미지 브랜치의 구조는 CAT3D 기반, 파라미터 약 250M
* CAT3D: 사진 몇 장과 카메라 위치로 새 시점 이미지를 생성하는 다중 시점 확산 모델(NeurIPS 2024)
* Elongation: 반사된 레이저 펄스가 퍼진 정도 | Raymap: 픽셀마다 카메라 광선의 시작점과 방향을 담은 값

Autoregressive Video with DAgger

직전 프레임 결과를 조건으로 한 autoregressive 생성

식: $P(C_t, L_t \mid x_t, C_{t-1}, L_{t-1})$ (C: 카메라 8대 영상, L: LiDAR, x: dashcam 프레임, t: 시점)

조건 입력: 직전 프레임 카메라·LiDAR latent의 채널 방향 연결

첫 프레임: dashcam 프레임만 사용, 학습 중 확률 0.5로 직전 프레임 조건 제거

DAgger로 drift 완화

원인: 학습은 정답 이력, 추론은 생성 이력을 조건으로 쓰는 불일치, 프레임마다 쌓이는 오차

방법: 학습 때도 직전 프레임 자리에 생성 프레임 입력, 정답 프레임 유지 확률 0.2

대응 관계: policy(정책)는 생성 모델, state(상태)는 지금까지 생성한 프레임, expert(모범)의 행동은 정답 다음 프레임

한계: 30초 이상 긴 영상에서 남는 drift

앞 단계 모델에서 이어 가는 4단계 학습

1단계: 단일 프레임 생성

2단계: 직전 프레임 조건 추가

3단계: 2단계 모델의 rollout(여러 프레임 연속 생성)으로 DAgger용 데이터 마련

4단계: DAgger 미세조정

* DAgger(Dataset Aggregation): 모델이 실제로 겪는 상태를 학습 데이터에 더해 다시 학습하는 모방학습 기법(Ross et al., 2011)

Image and Video Fidelity

평가 설정

평가 데이터: Fixed-Camera-to-AV(1,000개 × 3초), AV 앞쪽 왼편 범퍼 고정 카메라 입력, 상단 카메라 8대·LiDAR와 맞춰진 정답

복원 기준선: VGGT, π^3(dashcam 영상의 3D 복원으로 8개 시점 생성)

생성 기준선: dashcam 입력을 attention으로 받도록 개조한 X-Drive, CAT3D + LiDAR + CC인 Ours wo VC

방법	FID ↓	PSNR ↑	SSIM ↑	LPIPS ↓	FVD ↓
VGGT	250.93	14.73	0.433	0.491	2373.15
π^3	246.27	14.93	0.470	0.458	2007.35
X-Drive	8.30	18.61	0.536	0.345	–
Ours wo VC	6.88	18.69	0.531	0.346	293.73
Ours	6.47	19.06	0.539	0.316	278.12

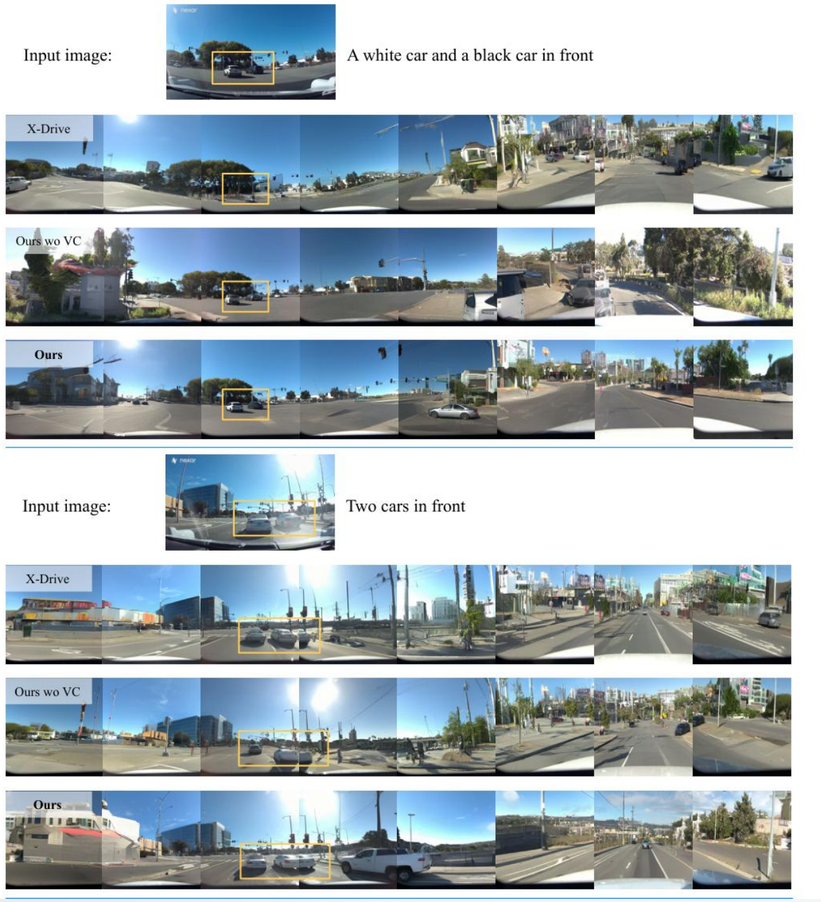


Figure 11. 실제 dashcam 입력에 대한 X-Drive, Ours wo VC, Ours의 8시점 출력

* FID(Frechet Inception Distance)·FVD(Frechet Video Distance): 실제·생성 이미지(영상) 분포 사이의 거리(낮을수록 좋음)
* PSNR(Peak Signal-to-Noise Ratio)·SSIM(Structural Similarity Index Measure): 정답과 얼마나 비슷한지(높을수록 좋음)
* LPIPS(Learned Perceptual Image Patch Similarity): 사람 눈 기준의 차이(낮을수록 좋음)

LiDAR Fidelity

Chamfer Distance: X-Drive 10.02, Ours 8.68(13.37% 감소)

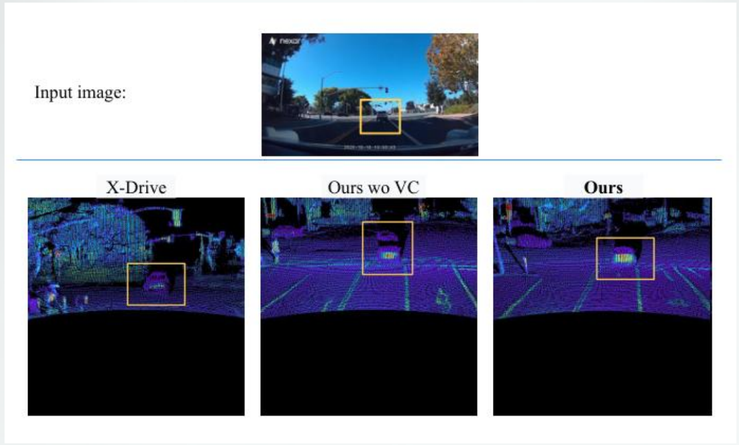
비교 조건: 모든 방법이 같은 LiDAR VAE 사용, VAE 차이 배제

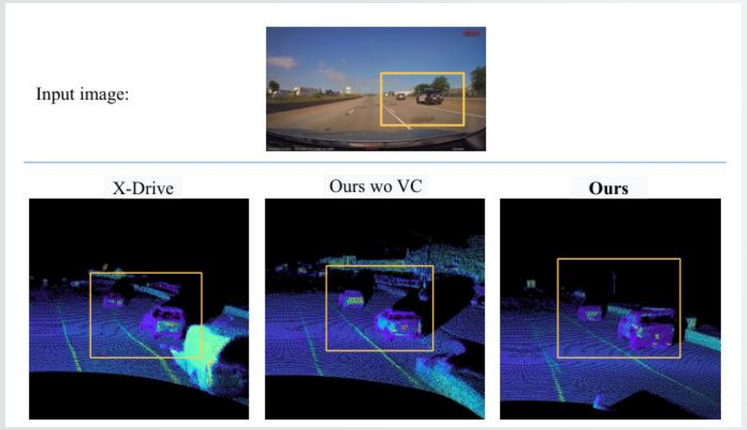
In-the-wild 입력의 정성 결과

형상: 트럭 같은 가까운 물체와 주변 정적 환경 유지

품질: 적은 노이즈, 더 정확한 반사 강도(intensity)

정렬: 함께 생성한 이미지의 같은 물체 위에 놓인 LiDAR 점





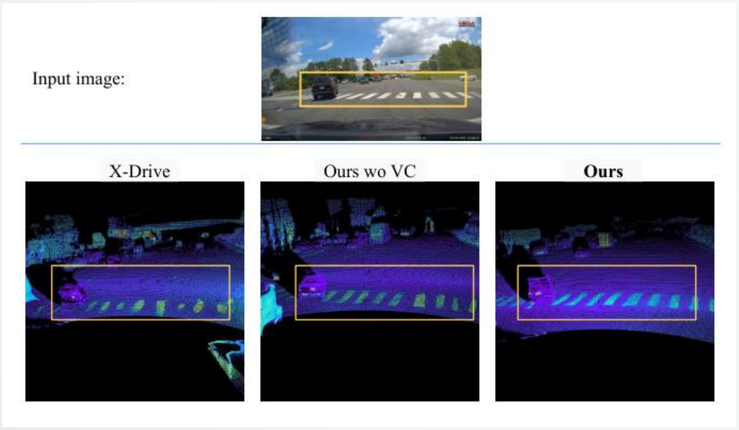


Figure 13. In-the-wild 입력에 대한 X-Drive, Ours wo VC, Ours의 LiDAR 출력

* Chamfer Distance: 두 점군에서 서로 가장 가까운 점 사이의 거리를 양방향으로 평균한 값(낮을수록 좋음)

Internet Video Generalization

학습에 없던 인터넷 영상의 카메라 8대 영상·LiDAR 변환

학습 데이터: 합성 paired data만 사용

입력 조건: 처음 보는 카메라 내부·외부 파라미터, 날씨, 장면 내용

대상 장면: 드문 충돌, 시야가 나쁜 야간, 진행 중인 사고 현장

결과: 주요 장면 요소 유지(저자 설명)

평가 방식: 정답이 없어 정성 평가만 수행



Figure 8. 드문 충돌, 어두운 야간, 사고 현장 영상의 변환 결과

VC and DAgger Ablation

Dashcam(블랙박스) 입력 방식과 LiDAR 동시 생성의 효과

이미지만 생성: 4개 지표 모두 VC가 CC보다 좋은 값

LiDAR 동시 생성: 이미지 LPIPS 0.307에서 0.316으로 변화, 저자는 뚜렷한 저하 없음으로 해석

구성	FID ↓	PSNR ↑	SSIM ↑	LPIPS ↓
CAT3D + CC (이미지만)	6.63	18.91	0.542	0.314
CAT3D + VC (이미지만)	6.20	19.12	0.543	0.307
CAT3D + CC + LiDAR	6.88	18.69	0.531	0.346
CAT3D + VC + LiDAR (Ours)	6.47	19.06	0.539	0.316

DAgger의 효과

정량: 전방 FVD 288.90에서 278.12로, 전방 FID 24.65에서 21.54로 감소

정성: DAgger가 없을 때 연속 생성 후반의 물체 흔들림과 깜빡임

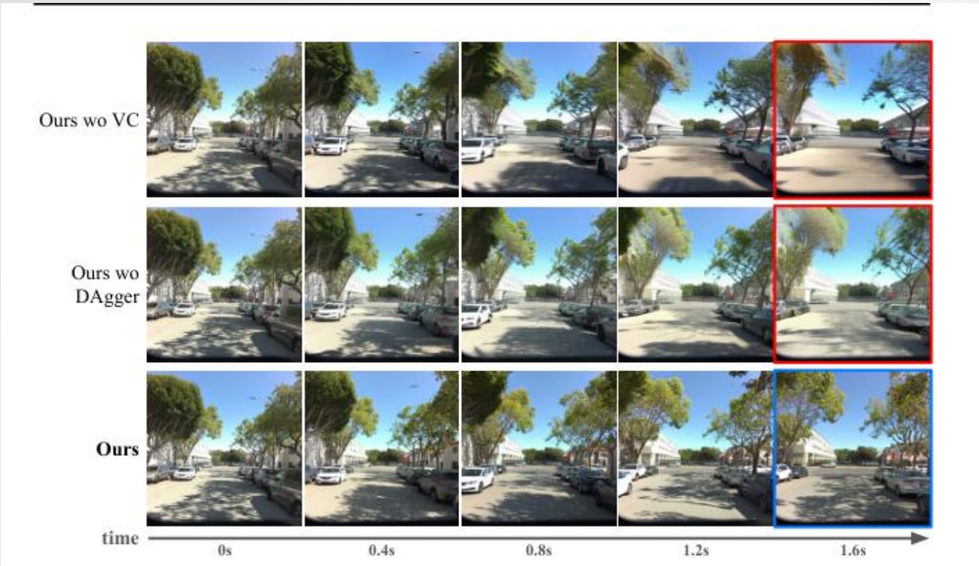


Figure 5. Ours wo VC, Ours wo DAgger, Ours의 연속 생성 비교(전방 시점, 0–1.6초)

* 표의 CAT3D는 모든 변형이 공유하는 이미지 생성 뼈대이며, CC(Channel Concatenation)/VC(View Concatenation)와 LiDAR 유무만 바꿔 비교

Downstream Perception Consistency

실제 데이터로 학습한 인지 모델을 파인튜닝 없이 생성 데이터에 적용

LiDAR: 차량 검출 모델

이미지: Panoptic-DeepLab 분할 모델

➡ 실제 데이터와 생성 데이터의 비슷한 결과 확인

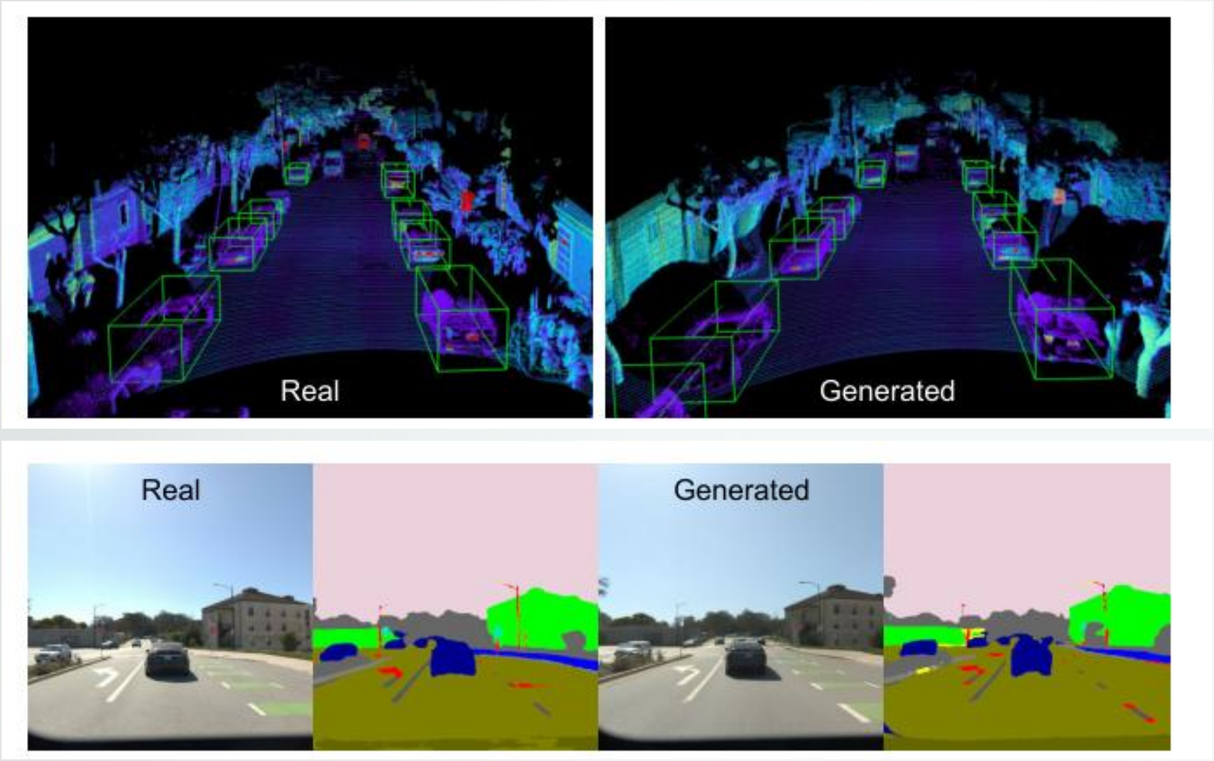


Figure 9, 10. 실제(왼쪽)와 생성(오른쪽) 데이터에 대한 LiDAR 검출과 이미지 분할 결과

* Panoptic-DeepLab: 픽셀마다 종류를 붙이고 물체를 개체별로 나누는 분할 모델

Long-tail Data from Accident Dashcam Video

사고 Dashcam(블랙박스) 영상의 long-tail 학습 활용 검토

Sensor2Sensor의 역할: 사고 영상을 사용 차량 형식의 센서 데이터로 변환

입력 가능 범위: 차량에 단 1인칭 블랙박스 영상

검토 데이터: AI Hub 교통사고 영상 데이터

구축: 2021년 구축, 2024년 1월 갱신

규모: 10초 단위 사고 영상 21,895건, 이미지 3,284,250장, 최대 3840×2160

구성: 차대차·차대보행자·차대자전거·차대이륜차 사고, 블랙박스와 CCTV, 1인칭과 3인칭 영상

라벨: 바운딩 박스, 사고 유형, 과실 비율, 날씨

* 출처 AI Hub 교통사고 영상 데이터(2026년 10월 확인), 내국인만 신청 가능

Undisclosed Components and Target-Vehicle Data

공개 여부와 무관하게 필요한 사용 차량의 다중 센서 로그

데이터: 비공개 Waymo 데이터, 공개 데이터셋으로 학습해도 해당 데이터셋 차량 형식의 출력

모델 코드·가중치: 미공개(2026년 10월 기준), 공개돼도 Waymo 차량(카메라 8대 + LiDAR) 형식으로 고정된 출력

조건: 사용 차량 로그로 paired data를 다시 만든 뒤 재학습

비공개 요소

4DGS 파이프라인·Dashcam(블랙박스) 보정값: 비공개

하이퍼파라미터: 이미지·LiDAR 해상도, 배치 크기, loss 가중치, 샘플링 단계 수, 실험으로 탐색 필요

추론 설정: 카메라 설정을 모르는 실제 dashcam의 raymap 결정 방법

Required Compute and Expected Gap

논문 규모 재현에 필요한 GPU시간

4DGS 복원: 장면당 30분~1시간 가정 시 10만 장면에 약 5만~10만 GPU시간

모델 학습: A100급 약 128장 × 1~3주 가정 시 약 2만~6만 GPU시간

DAgger용 연속 생성: 반복 확산 샘플링에 드는 별도 계산

공개 데이터셋 대체

데이터 규모: Waymo Open Perception 20초 세그먼트 2,030개, nuScenes 20초 scene 1,000개

센서 구성: Waymo Open은 카메라 5대로 360도 미포함, nuScenes는 LiDAR 32채널

기반 모델: Google 내부 모델에서 시작한 CAT3D, 공개 모델로 대체 시 성능이 달라질 수 있음

같은 품질 재현에 필요한 데이터와 계산 규모

데이터: 사용 차량 기준 10초 장면 10만 개, 약 280시간 분량의 다중 센서 로그

계산: A100 8장 기준 4DGS 복원과 학습에 약 600일 정도 소요

* 논문 기재 값은 TPU 128개, 단계별 80k·40k·20k step뿐이며 학습 시간과 배치 크기는 없음
* GPU시간은 A100급 기준 추정치
* Waymo Open Dataset은 비상업적 용도로만 사용 가능